LUCA: un pipeline multiagente híbrido XBRL–LLM para la generación automática de *investment memos* de informes 10-K en hardware de consumo

Ignacio Queipo de Llano Pérez-Gascón
ICAI, Universidad Pontificia Comillas
Madrid, España
202214125@alu.comillas.edu

***Resumen*—LUCA es un pipeline multiagente que ingiere un documento financiero regulatorio (un informe 10-K de SEC EDGAR) y produce un *investment memo* estructurado. Su decisión de diseño central es la extracción *híbrida*: las cifras numéricas se obtienen de los datos XBRL del propio documento (sin LLM, exactas y deterministas), mientras que el modelo de lenguaje, un Qwen 2.5 7B cuantizado a Q4_K_M servido localmente con Ollama, se reserva únicamente para el contenido cualitativo (riesgos, discusión y *outlook*). Todo el sistema se ejecuta en una única GPU de consumo (RTX 4060, 8 GB) y no emplea modelos externos ni APIs de pago en ninguna etapa. Sobre un *gold standard* anotado manualmente de 60 puntos de dato (6 métricas $\times$ 10 empresas), el extractor estructurado alcanza un 100% de precisión (determinista), frente al 50.0–51.7% del mejor baseline LLM (no determinista entre ejecuciones) y un 3.3% de un baseline LLM ingenuo; una brecha de $\approx$48–50 puntos porcentuales (pp) que motiva la arquitectura híbrida. En la capa cualitativa, validamos manualmente la extracción de riesgos contra los informes originales y documentamos un patrón de sobre-extracción no uniforme, que constituye un resultado honesto sobre los límites de un modelo de 7B en hardware de consumo.**

***Términos índice*—extracción financiera, XBRL, modelos de lenguaje, sistemas multiagente, hardware de consumo, 10-K, alucinación numérica.**

I. Introducción

El análisis de informes financieros regulatorios es una tarea intensiva en conocimiento experto. Un informe anual 10-K de la *Securities and Exchange Commission* (SEC) estadounidense supera con frecuencia los dos millones de caracteres de HTML y combina estados financieros consolidados, una sección de factores de riesgo (Item 1A) y una discusión de la dirección (Item 7). Extraer de forma fiable las magnitudes numéricas y sintetizar el contenido cualitativo es el trabajo que realiza un analista junior, y un candidato natural a la automatización.

Un *investment memo* sintetiza ese trabajo en un documento estructurado: un resumen ejecutivo, una visión del negocio, los aspectos financieros con sus cifras clave, un análisis de riesgos y unas perspectivas. Producirlo a mano para una sola empresa lleva horas de lectura y tabulación, y el cuello de botella no es el juicio analítico sino la extracción fiable de magnitudes y la lectura de secciones extensas como los factores de riesgo. Automatizar esa capa de extracción y síntesis, conservando la trazabilidad hasta el documento fuente, es el objetivo de LUCA.

Las aproximaciones recientes basadas en grandes modelos de lenguaje (LLM) presentan dos modos de fallo en este dominio. Por un lado, los enfoques *LLM-only*, que entregan el documento al modelo y le piden que extraiga las cifras, son frágiles: el modelo alucina valores numéricos, confunde columnas de ejercicios adyacentes y mezcla magnitudes consolidadas con atribuibles. La literatura de evaluación de alucinación [1] y los benchmarks de razonamiento numérico financiero [2], [3] documentan ampliamente esta limitación. Por otro lado, los sistemas que sí alcanzan precisión de grado experto suelen depender de modelos propietarios de gran tamaño servidos tras APIs comerciales cerradas [4], lo que introduce coste por consulta, dependencia de un proveedor y envío de datos a terceros.

Este trabajo parte de una restricción deliberada y verificable: *todo el sistema debe ejecutarse en hardware de consumo* (una GPU RTX 4060 de 8 GB) con un modelo abierto y cuantizado servido localmente, sin ninguna llamada a servicios de pago. La pregunta de investigación que abordamos es: *¿puede un pipeline multiagente sobre hardware de consumo, usando un modelo de 7B local solo allí donde aporta valor, igualar la precisión numérica de un experto al mismo tiempo que produce un memo cualitativo utilizable?*

Nuestra respuesta es una arquitectura híbrida en la que la división del trabajo entre componentes deterministas y el LLM es explícita. Las contribuciones del trabajo son tres:

1) **Una arquitectura híbrida XBRL+LLM** en la que las cifras provienen de los *facts* XBRL del documento (sin LLM, exactas) y el modelo de 7B local se limita al texto cualitativo. Esto es lo que hace viable ejecutar el pipeline completo en 8 GB de VRAM.

2) **Una comparación empírica de precisión** frente a dos baselines LLM-only (ingenuo y estructurado), sobre un *gold standard* anotado a mano, que cuantifica la ventaja de la extracción estructurada (Tabla III).
3) **Un análisis honesto del techo de calidad** del modelo de 7B en la parte cualitativa, incluyendo un patrón de sobre-extracción de riesgos validado manualmente contra los informes originales y reportado como limitación.

LUCA es un proyecto de *AI Lab* que reutiliza, en el dominio financiero, la arquitectura multiagente de un sistema previo orientado a revisiones sistemáticas. El interés metodológico de este traslado es comprobar que la misma descomposición en agentes especializados, con una frontera explícita entre componentes deterministas y generativos, generaliza a otro dominio intensivo en documentos. El resto del artículo se organiza así: la §III describe la arquitectura; la §IV, la implementación y las pruebas; la §V, la metodología de evaluación; la §VI, los resultados; la §VII, la discusión; y la §VIII, el trabajo futuro.

II. Trabajo relacionado

LLMs en el dominio financiero. BloombergGPT [4] demostró las ventajas de un modelo de 50B entrenado sobre un corpus financiero masivo, pero su escala y su carácter propietario lo sitúan fuera del alcance del hardware de consumo. En el extremo de los modelos especializados ligeros, FinBERT [5] adaptó BERT al análisis de sentimiento financiero. Los benchmarks FinQA [2] y TAT-QA [3] formalizaron el razonamiento numérico sobre datos financieros tabulares y textuales, y evidenciaron que la extracción de cifras exactas es un punto débil persistente de los modelos generativos. Estos benchmarks, sin embargo, plantean preguntas sobre tablas o fragmentos ya seleccionados, mientras que LUCA opera sobre el documento 10-K completo, donde el reto incluye *localizar* la cifra correcta en cientos de miles de caracteres antes de leerla. Nuestro resultado del baseline ingenuo muestra que ese problema de localización, y no solo el de lectura, es crítico cuando no se dispone de un acceso estructurado a los datos.

Alucinación y fiabilidad numérica. El estudio de Ji *et al.* [1] ofrece una taxonomía de la alucinación en generación de lenguaje natural. En extracción financiera, la alucinación de una sola cifra invalida un memo completo, lo que motiva nuestra decisión de no delegar números al LLM. Técnicas de *prompting* como *chain-of-thought* [6] mejoran el razonamiento, pero no garantizan la exactitud de una magnitud copiada de un estado financiero.

Sistemas multiagente con LLMs. Marcos como ReAct [7], que entrelaza razonamiento y acción, y AutoGen [8], que orquesta múltiples agentes conversacionales, han popularizado la descomposición de tareas complejas en agentes especializados. LUCA adopta esta filosofía de descomposición, pero con una diferencia metodológica clave: no todos los agentes usan el LLM; los agentes numéricos son deterministas por diseño. Frente a los marcos en los que cada agente es una instancia del LLM que conversa con las demás, LUCA traza una frontera explícita entre lo que resuelve el dato estructurado y lo que resuelve el modelo, y esa frontera es la que se evalúa en este trabajo.

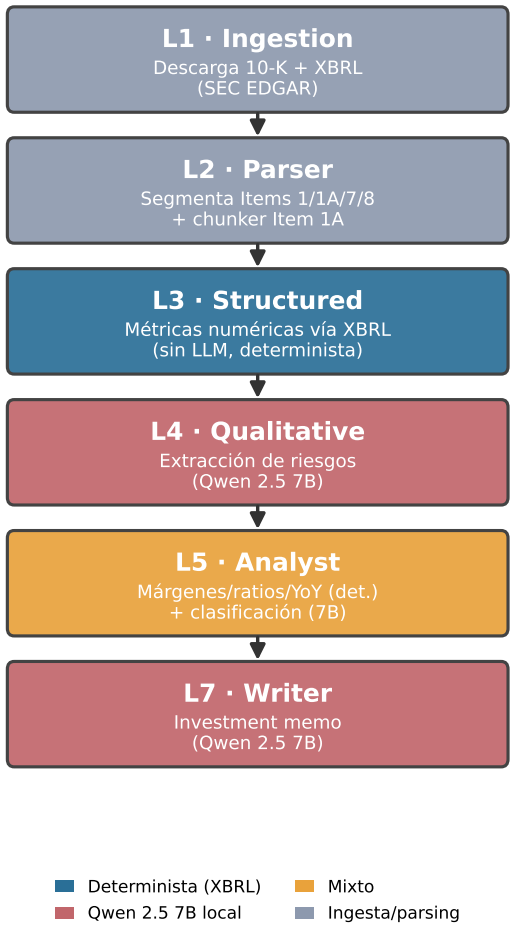


Fig. 1. Arquitectura del pipeline L1→L7. El color distingue los componentes deterministas (L3, vía XBRL) de los que invocan el Qwen 2.5 7B local (L4, L7) y los mixtos (L5: aritmética determinista + clasificación con LLM).

Modelos abiertos y locales. La disponibilidad de modelos abiertos competentes como la familia LLaMA [9] y Qwen 2.5 [10], junto con la cuantización y los servidores locales de inferencia, ha hecho viable ejecutar modelos de 7B en GPUs de consumo. LUCA se apoya en esta línea: emplea Qwen 2.5 7B cuantizado a Q4_K_M sobre Ollama, y trata su capacidad limitada como una restricción del problema, no como un defecto a ocultar.

III. Arquitectura del sistema

LUCA se organiza como un pipeline de ocho agentes. La Tabla I resume el rol y el estado de implementación de cada uno, y la Fig. 1 muestra el flujo de datos y, mediante color, qué agentes son deterministas y cuáles invocan el modelo de 7B local.

TABLE I
AGENTES DE LUCA Y SU ESTADO. "EVALUADO" SIGNIFICA MEDIDO CONTRA EL *gold standard* (§V).

Agente	Rol	Estado
L1 Ingestion	Descarga 10-K + XBRL (EDGAR)	Impl., evaluado
L2 Parser	Segmenta Items 1/1A/7/8	Impl., evaluado
L2 *chunker*	Troceado de Item 1A	Impl., evaluado
L3 Structured	Métricas numéricas (XBRL)	Impl., evaluado
L4 Qualitative	Extracción de riesgos	Impl. (parcial)
L5 Analyst	Métricas derivadas + clasif.	Impl. (parcial)
L7 Writer	*Investment memo* (Qwen)	Impl. (demo AAPL)
L6 Comparables	Análisis comparado	Trabajo futuro
L8 Explainer	Excel + *explainability*	Trabajo futuro

A. Principio híbrido

La premisa que vertebra el diseño es que los datos numéricos deben provenir de los *facts* XBRL de *companyfacts* (deterministas, gratuitos y exactos), mientras que el LLM se restringe al texto cualitativo. Esta separación no es solo una decisión de calidad: es lo que hace que el pipeline completo quepa en 8 GB de VRAM, porque el modelo de 7B nunca tiene que procesar los megabytes de tablas financieras del documento.

B. L1 – Ingestion

L1 resuelve el *ticker* a su CIK mediante el mapa de la SEC, descarga el *submissions* JSON para localizar el 10-K más reciente, y obtiene tanto el HTML del informe como el *companyfacts* XBRL. Las descargas se cachean en disco por *(ticker, accession)* y se respeta el límite de tasa de EDGAR. La salida es un diccionario con el HTML, los *facts* XBRL, la fecha de *filing* y el número de *accession* para trazabilidad.

C. L2 – Parser

L2 convierte el HTML a texto plano y segmenta el documento en los Items 1, 1A, 7 y 8. La segmentación evita un error frecuente: anclar las secciones en el índice (*table of contents*) en lugar del cuerpo, lo que se resuelve detectando el índice por su estructura DOM y exigiendo el título canónico de la SEC. Sobre Item 1A actúa además un *chunker* específico, descrito a continuación.

D. L2b – Chunker de Item 1A

La sección de factores de riesgo es demasiado larga para una sola ventana de contexto, por lo que requiere un troceado que respete su estructura. Un hallazgo de diseño relevante es que los 10-K en formato iXBRL no marcan los encabezados con etiquetas semánticas (`<h1>`, `<b>`), sino con CSS en línea del tipo `font-weight:700`. El *chunker* detecta, por tanto, los anclajes *bold-leading*: el primer texto de un `<div>` cuyo ancestro tiene *font-weight* $\geq$600. Cada bloque del cuerpo queda delimitado por anclajes consecutivos, de modo que se corresponde con un factor de riesgo del documento.

Tres filtros anti-falsos-positivos descartan anclajes espurios: numéricos puros, patrones de número de página, y encabezados repetidos tres o más veces en el documento. Un heurístico adicional detecta el *Risk Factor Summary* (un encabezado corto seguido de al menos tres *bullets* en los primeros 5 000 caracteres) y lo marca con una bandera `in_summary`, señal que la capa de deduplicación de trabajo futuro podrá aprovechar. Por último, un bloque que excede las 4 000 *tokens* ($\approx$16 000 caracteres) se subdivide con un solape de 500 caracteres, y un relleno de huecos garantiza la cobertura íntegra de la sección.

E. L3 – Structured Extractor

L3 es el corazón determinista del sistema y la fuente de todas las cifras del memo. Para cada métrica canónica mantiene una cadena ordenada de etiquetas US-GAAP candidatas (preferente primero, alternativas después) y selecciona el *fact* anual más reciente a lo largo de toda la cadena, con desempate por prioridad de etiqueta. Filtra por formulario (`10-K`), periodo fiscal (`FY`), unidad (USD o USD/acción) y duración ($\geq$320 días, para rechazar trimestres etiquetados como anuales). Un *guard* de recencia (730 días respecto a la fecha de *filing*) descarta etiquetas obsoletas heredadas del histórico agregado de *companyfacts*. L3 nunca usa el LLM y nunca lanza excepción ante XBRL ausente: devuelve `None` y continúa.

Un ejemplo ilustra por qué la selección recorre toda la cadena en lugar de detenerse en la primera etiqueta. Para los ingresos de Apple, la etiqueta heredada `Revenues` conserva en *companyfacts* un *fact* obsoleto de FY2017, mientras que la cifra vigente bajo ASC-606 vive en `RevenueFromContractWithCustomerExcludingAssessedTax`. Una estrategia de "primera etiqueta con dato válido" devolvería el valor obsoleto; la estrategia de "*fact* anual más reciente en toda la cadena", con desempate por prioridad, selecciona el correcto. El campo `tag_used` registra qué etiqueta resolvió finalmente, lo que permite auditar la cobertura de etiquetas preferentes frente a alternativas.

F. L4 – Qualitative Extractor

L4 extrae los factores de riesgo del Item 1A. Recibe los bloques del *chunker* y, por bloque, invoca a Qwen para producir, en JSON, una lista de riesgos con título, resumen en español y cita literal de trazabilidad. El sistema asigna los identificadores de forma determinista (el LLM no es fiable asignando identificadores únicos) y remapea los identificadores de bloque al formato del contrato. Ante un JSON malformado, el bloque se descarta con un aviso y el pipeline continúa, sin abortar.

G. L5 – Analyst

L5 tiene dos responsabilidades. La primera es *determinista*: calcula métricas derivadas (márgenes neto y operativo, ROE, ROA, *debt-to-equity* y crecimiento interanual o YoY) mediante aritmética pura sobre las cifras de L3. Como L3 expone solo el ejercicio corriente, el YoY se obtiene leyendo el *fact* del

año anterior directamente de los datos XBRL, reutilizando la lógica de selección de L3 y aplicando el mismo *guard* de recencia para no comparar contra valores obsoletos. La segunda responsabilidad sí usa el LLM: clasifica cada riesgo de L4 en una de seis categorías (*operational*, *financial*, *regulatory*, *market*, *technological*, *geopolitical*). La clasificación se realiza en lotes para evitar respuestas truncadas.

H. L7 – Writer

L7 redacta el *investment memo* final en español, en seis secciones: (1) *Resumen ejecutivo*, (2) *Visión general* del negocio a partir del Item 1, (3) *Aspectos financieros*, (4) *Análisis de riesgos* sobre los riesgos clasificados por L5, (5) *Perspectivas y guidance*, y (6) *Apéndice* de trazabilidad. La tabla de aspectos financieros y el apéndice se renderizan de forma determinista a partir de las cifras de L3 y L5; el LLM solo escribe la prosa alrededor de esas cifras fijas, de modo que nunca emite una magnitud numérica. Las temperaturas de generación se calibran por sección (más baja para las factuales, algo mayor para el *outlook*).

La sección de *outlook* merece una nota de diseño. Como los *forward-looking statements* y el análisis de tono directivo quedan fuera de alcance, esta sección no dispone de su materia prima natural; en lugar de fabricar previsiones, L7 redacta unas perspectivas prudentes basadas solo en los riesgos y las métricas disponibles, y añade una nota explícita de limitación. Es una decisión deliberada para no sobre-atribuir capacidad de previsión al sistema.

I. Un memo de ejemplo

Para ilustrar la salida de L7, este es el comienzo del *Resumen ejecutivo* del memo generado para AAPL, con cifras deterministas procedentes de L3 y L5:

> *"Apple Inc. (AAPL) registró ingresos de 416.161 millones de dólares en su ejercicio fiscal 2025, representando un crecimiento del 6.4% interanual. El beneficio neto alcanzó los 112.010 millones de dólares con un margen neto del 26.9%. Este periodo también se destacó por un sólido margen operativo del 32.0%, y un aumento del 19.5% interanual en el beneficio neto."*

Las magnitudes (416.161 M$, 26.9%, 6.4%) no las redacta el modelo: se inyectan ya formateadas y el LLM solo las parafrasea, de modo que el memo es factualmente correcto aunque la prosa del 7B sea limitada.

J. Alcance evaluado en este trabajo

Evaluados de extremo a extremo: L1–L3 y el *chunker* de Item 1A. Implementados y demostrados, pero aún no evaluados cuantitativamente en calidad: L4 (solo riesgos), L5 (métricas derivadas deterministas y clasificación con LLM) y L7 (memo, demostrado sobre AAPL). Los agentes L6 y L8, así como los *forward-looking statements* y el análisis de tono directivo, quedan como trabajo futuro.

TABLE II
PARÁMETROS DE CONFIGURACIÓN PRINCIPALES POR AGENTE.

Agente	Parámetros
L3	duración mínima anual 320 días; *guard* de recencia 730 días; unidad USD/USD-acción
L4	temperatura 0.2; *max input* 24 000 car.; *max output* 1 500 *tokens*
L5	6 categorías; temperatura de clasificación 0.1; lote de 20 riesgos
L7	temp. factual 0.2; temp. *outlook* 0.5; 800 *tokens*/sección
LLM	`qwen2.5:7b-instruct-q4_K_M`; `num_ctx` 8 192

IV. Implementación y pruebas

A. Configuración por agente

LUCA externaliza todos los umbrales y temperaturas a ficheros de configuración; no hay valores "mágicos" en el código. La Tabla II recoge los parámetros principales. Esta disciplina permite recalibrar el sistema sin tocar la lógica y documenta de forma trazable cada decisión cuantitativa.

B. Presupuesto de cómputo

La viabilidad en 8 GB de VRAM no es accidental, sino consecuencia directa del principio híbrido. Los estados financieros completos de un 10-K (decenas de miles de caracteres por tabla) nunca llegan al modelo: L3 los resuelve vía XBRL. El LLM solo procesa fragmentos acotados del Item 1A (bloques de hasta 4 000 *tokens*) y secciones cortas para el memo, siempre dentro de una ventana de 8 192 *tokens*. Intentos preliminares de alimentar al modelo ventanas de 40 000 caracteres o ampliar el contexto provocaban desbordamiento de memoria por la caché KV, lo que confirma que la restricción de hardware moldea el diseño.

C. Diseño de prompts

Los *prompts* siguen una convención consistente: instrucción de sistema en inglés (el modelo sigue instrucciones con más fiabilidad) y contenido que puede ir en español, con salida en JSON estricto. En L4, al modelo se le entrega un único bloque del Item 1A y se le pide extraer solo los riesgos presentes en ese bloque, con un resumen en español y una cita literal de trazabilidad; se le prohíbe explícitamente inventar riesgos y asignar identificadores, que el sistema genera de forma determinista. En L5, la clasificación recibe un conjunto cerrado de seis categorías con una definición breve de cada una y devuelve, por riesgo, una única categoría. Las salidas se parsean con tolerancia a las envolturas de código (*fenced JSON*) que el modelo añade ocasionalmente; ante un fallo de *parsing*, el elemento se degrada con un aviso en lugar de abortar.

Un detalle de robustez merece mención: un único lote de clasificación con $\sim$100 riesgos provocaba que el modelo truncara su respuesta JSON y dejara la mayoría sin clasificar. Trocear la clasificación en lotes de 20 riesgos resolvió el problema, lo que ilustra que parte de los fallos atribuibles

"al modelo" son en realidad inestabilidad de la generación estructurada en respuestas largas.

D. Pruebas

El sistema se acompaña de una batería de 240 pruebas unitarias y de integración. Todas las llamadas de red (EDGAR) y al LLM (Ollama) se simulan con *mocks*, de modo que la suite es completamente *offline* y determinista. Las pruebas cubren la resolución de cadenas de etiquetas en L3, los invariantes del esquema de salida de L4 (unicidad de identificadores, existencia de referencias a bloques), la aritmética de L5, y el renderizado determinista de las cifras del memo en L7.

E. Orquestación y artefactos

El pipeline se invoca desde una interfaz de línea de comandos que, con una única opción, encadena L1→L2→L3→L4→L5→L7 para un *ticker* y escribe el memo final. Cada etapa persiste sus resultados intermedios en disco como artefactos auditables: el JSON de riesgos de L4 con su *sidecar* de texto literal por bloque, el JSON de análisis de L5 con las métricas derivadas y los riesgos clasificados, y el memo en Markdown de L7. Esta materialización por etapas cumple dos funciones: permite la revisión humana de las salidas cualitativas antes de que ninguna afirmación entre en un informe, y desacopla las etapas, de modo que regenerar el memo no exige repetir la costosa extracción de riesgos. Las cifras de las tablas y figuras del propio artículo se regeneran desde los CSV de evaluación mediante un único *script*, lo que garantiza la coherencia entre el texto, las tablas y los gráficos.

F. Latencia

Las ejecuciones en vivo sobre la RTX 4060 dan una idea del coste temporal de la capa cualitativa. La extracción de riesgos de L4 sobre AAPL (33 bloques) tardó del orden de seis minutos, y sobre JPM (57 bloques) alrededor de diez, dominadas por las llamadas secuenciales al modelo por bloque. La clasificación de L5, por lotes, ronda el minuto, y la redacción del memo de seis secciones por L7, en torno a medio minuto. Estos tiempos, asumibles para un análisis por empresa, confirman que el cuello de botella no es la GPU sino el número de invocaciones secuenciales del modelo; L3, al ser determinista, es prácticamente instantáneo.

V. Metodología de evaluación

A. Gold standard

El *gold standard* cubre 10 empresas conocidas (AAPL, MSFT, GOOGL, META, AMZN, NVDA, JPM, KO, JNJ, WMT) y 6 métricas *core* (ingresos, beneficio neto, beneficio operativo, activos totales, patrimonio neto y BPA diluido), lo que da $N = 60$ puntos de dato anotados manualmente contra los informes de la SEC. La anotación es independiente del sistema: ninguna celda se pre-rellena con salidas de L3 ni del LLM. La comparación es *numérica*, con una tolerancia relativa del 0.5%, y trata como coincidencia el caso en que tanto el valor anotado como el predicho son nulos (por ejemplo, el beneficio operativo de ciertos bancos, que no publican ese subtotal).

B. Enfoques comparados

Comparamos tres enfoques que comparten el mismo modelo y el mismo comparador numérico:

- **L3** – extracción híbrida estructurada vía XBRL (sin LLM).
- **Baseline LLM *structured*** – Qwen recibe las primeras tablas financieras consolidadas extraídas por L2 y debe devolver las cifras en JSON.
- **Baseline LLM *naive*** – Qwen recibe una porción *head*+*tail* del texto plano del informe (los primeros 5 000 y los últimos 35 000 caracteres, dentro del presupuesto de contexto del 7B en 8 GB).

Los dos baselines son LLM-only: representan, respectivamente, el techo razonable y el suelo de una extracción sin XBRL.

C. Comparador numérico

La comparación entre el valor anotado y el predicho es numérica, no textual. El cargador del *gold standard* normaliza separadores de millar y coacciona los valores a punto flotante, de modo que "416,161" y `416161000000` se comparan como magnitudes, no como cadenas. Dos valores coinciden si su error relativo es inferior al 0.5%; esta tolerancia absorbe los redondeos de presentación (por ejemplo, una cifra publicada en millones frente al valor exacto en unidades) sin admitir errores reales de extracción. Cuando ambos valores son nulos se cuenta como coincidencia, lo que captura correctamente los subtotales que un emisor no publica. El mismo comparador se aplica a los tres enfoques, de modo que la comparación es homogénea.

El presupuesto de entrada de cada baseline se fijó para ser justo dentro de la restricción de 8 GB. El baseline *naive* recibe 5 000 caracteres de cabecera (portada y contexto inicial) más 35 000 de cola (notas y secciones finales), unidos por un separador explícito, lo que suma unos 40 000 caracteres (≈10 000 *tokens*); ampliar este presupuesto desbordaba la memoria. El baseline *structured* recibe las primeras tablas financieras consolidadas que L2 identifica mediante un filtro doble (presencia de importes en dólares y de palabras clave de estados consolidados), con un tope de cinco tablas; este filtro evita que la portada del formulario o las tablas de desglose geográfico desplacen a los estados financieros. Ambos baselines comparten con L4, L5 y L7 el mismo cliente y modelo, de modo que la diferencia medida es atribuible al *acceso a los datos*, no al modelo.

D. Entorno

El modelo es `qwen2.5:7b-instruct-q4_K_M` servido con Ollama sobre una RTX 4060 de 8 GB. No interviene ningún modelo externo ni API de pago. El contexto se fija en 8 192 *tokens*, el máximo manejable en esta GPU sin desbordar la caché KV.

VI. Resultados

La Tabla III recoge la precisión por métrica de los tres enfoques, y la Fig. 2 la desglosa para L3. La Fig. 3 compara los tres enfoques por métrica y en agregado.

TABLE III
PRECISIÓN DE EXTRACCIÓN POR MÉTRICA (N=60): XBRL HÍBRIDO (L3) FRENTE A BASELINES LLM-ONLY, EN UNA EJECUCIÓN REPRESENTATIVA. L3 ES TOTALMENTE DETERMINISTA (XBRL, SIN LLM); LOS BASELINES LLM NO SON DETERMINISTAS POR SEED Y VARÍAN $\pm$1–2 FILAS ENTRE EJECUCIONES (STRUCTURED OBSERVADO EN 50.0–51.7%), POR LO QUE LA BRECHA L3−STRUCTURED ES ≈48–50 PP SEGÚN LA EJECUCIÓN. CIFRAS REGENERADAS DESDE LOS CSV DE EVALUACIÓN.

Métrica	L3 (XBRL)	LLM structured	LLM naive
Ingresos	100.0%	40.0%	0.0%
Bº neto	100.0%	30.0%	0.0%
Bº op.	100.0%	50.0%	20.0%
Activos tot.	100.0%	50.0%	0.0%
Patrim. neto	100.0%	50.0%	0.0%
BPA diluido	100.0%	80.0%	0.0%
Global	**100.0%**	**50.0%**	**3.3%**

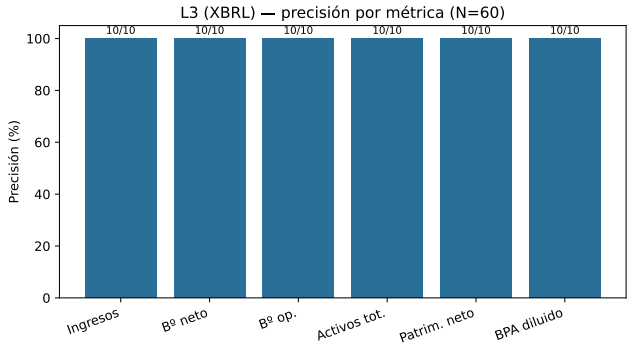


Fig. 2. Precisión de L3 (extracción estructurada vía XBRL) por métrica ($N = 60$). Cada barra anota las coincidencias sobre el total.

A. Resultado agregado

L3 alcanza un **100% (60/60)** de precisión, de forma determinista. El baseline *structured* se sitúa en el **50.0%** en la ejecución reportada (51.7% en una ejecución previa con el mismo gold), y el baseline *naive* en un **3.3% (2/60)**. La brecha entre L3 y el mejor baseline es de ≈48–50 pp, y entre L3 y el ingenuo, de ≈96–97 pp. Esta diferencia es el resultado central del trabajo: las cifras no deben dejarse en manos de un modelo de 7B.

La precisión de L3 pasó de un 98.3% en una iteración previa a un 100% tras resolver el único fallo pendiente: el beneficio operativo de JNJ, que el emisor no publica como subtotal. Al anotarlo como nulo y devolver L3 también nulo gracias al *guard* de recencia, la coincidencia es legítima y no un ajuste *ad hoc* de los datos. La brecha entre el baseline *structured* y el *naive* es a su vez de ≈47 pp, lo que sitúa el aporte de seleccionar tablas financieras (frente a una ventana ciega del texto) en un orden de magnitud comparable al aporte de XBRL sobre las tablas.

B. Análisis por métrica

El patrón por métrica es informativo. El baseline *naive* no extrae *ninguna* cifra correcta de forma genuina: sus dos únicas coincidencias son casos de beneficio operativo nulo en un banco y un conglomerado (*null=null*), por lo que su señal efectiva es ≈0%. La causa es estructural: con una ventana *head+tail*, el estado de resultados consolidado, que vive hacia la mitad del documento, queda fuera de contexto en casi todas las empresas del corpus.

El baseline *structured* se comporta mejor en métricas de presentación estandarizada. El BPA diluido es la métrica más robusta (80%): es invariablemente la última línea del estado de resultados, con formato `$X.XX` y etiqueta "*Diluted*", y el modelo la identifica con fiabilidad. En cambio, ingresos y beneficio neto caen al 30–40%: el modo de fallo dominante es la confusión columnar cuando el estado presenta tres ejercicios en columnas adyacentes sin encabezados claros por columna, y la ambigüedad entre cifras consolidadas y atribuibles. L3 no sufre ninguno de estos problemas porque cada *fact* XBRL lleva su periodo, su unidad y su contexto explícitos.

C. Análisis por empresa y decisiones de anotación

El comportamiento agregado oculta patrones por empresa que conviene explicitar, porque informan tanto de la fiabilidad de L3 como de los modos de fallo de los baselines.

Confusión multi-ejercicio en *structured*. El fallo persistente del baseline *structured* no se explica por el tamaño bruto del documento: JPM tiene el HTML más grande del corpus y *structured* acierta 5 de 6 métricas, mientras que KO, con un Item 8 de mayor tamaño, falla 5 de 6. La dimensión relevante es la *densidad multi-ejercicio* del estado de resultados: GOOGL, META y AMZN presentan tres ejercicios en columnas adyacentes sin encabezados claros por columna, y el modelo alinea sistemáticamente los valores con el año equivocado. Es el mismo mecanismo que produce la ambigüedad consolidado/atribuible.

Verificación de *fiscal year*. Antes de comparar, verificamos que el ejercicio anotado coincide con el que descarga L3 en cada par (*ticker*, métrica). No se detectó desfase temporal: NVDA y WMT se anotan en FY2026 y el resto en FY2025, en concordancia con los *filings* cacheados.

Decisiones de criterio en el *gold standard*. Dos casos exigieron una decisión documentada. En WMT, el beneficio neto se fijó en la cifra atribuible (no la consolidada con intereses minoritarios) por consistencia con la convención del BPA, que L3 extrae de `EarningsPerShareDiluted`. En JNJ y JPM, el beneficio operativo se anota como nulo porque el emisor no publica ese subtotal en su estado de resultados; L3 también devuelve nulo gracias al *guard* de recencia, que descarta un *fact* antiguo de `OperatingIncomeLoss`, de modo que la coincidencia *null=null* es legítima. Estas decisiones son independientes del sistema: el *ground truth* se ancla en el documento, no en la salida de ningún agente.

VII. DISCUSIÓN

A. Por qué la extracción estructurada gana

La brecha de ≈48–50 pp confirma que el problema de la extracción numérica es de *fiabilidad*, no de comprensión. El modelo de 7B "entiende" qué es el beneficio neto, pero no lo localiza ni lo copia de forma consistente en un documento largo y densamente tabular. XBRL resuelve el problema en

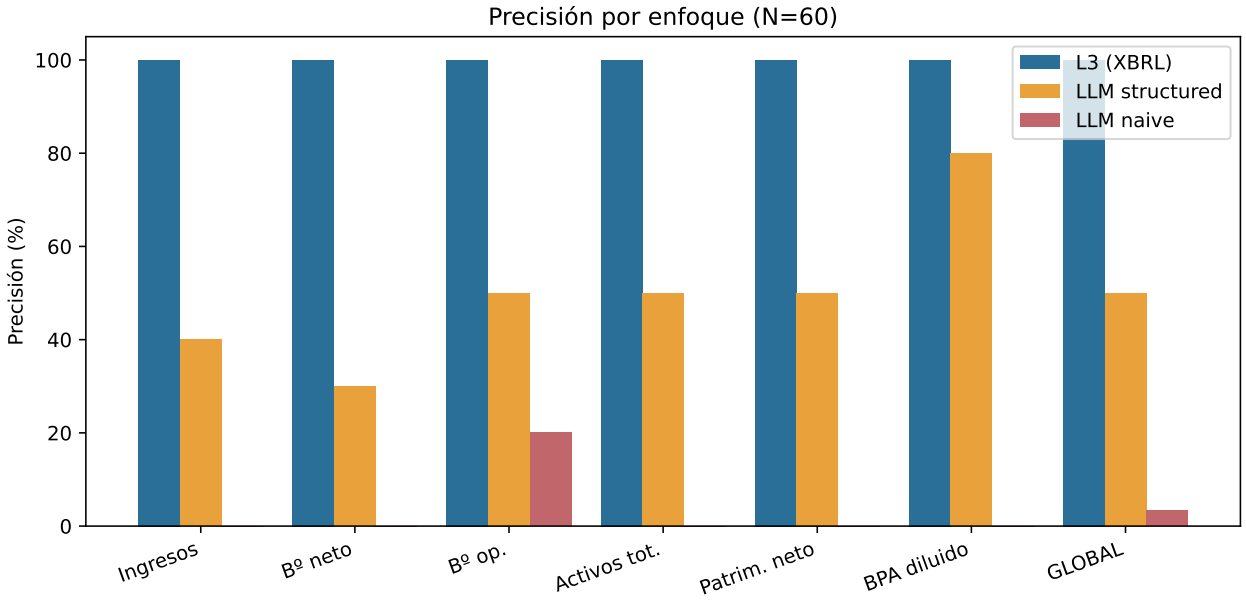


Fig. 3. Precisión por enfoque: XBRL híbrido (L3) frente a los baselines LLM *structured* y *naive*, por métrica y en agregado (GLOBAL).

el origen: la cifra ya viene etiquetada semánticamente por el emisor. La arquitectura híbrida pone así cada componente donde es fuerte.

El fracaso casi total del baseline *naive* (3.3%) tiene una causa geométrica además de cognitiva. El estado de resultados consolidado de Apple, por ejemplo, comienza alrededor del carácter 139.000 de un texto plano de unos 220.000; con una ventana *head+tail* de 5.000+35.000 caracteres, la zona central donde viven las cifras del ejercicio más reciente queda sistemáticamente fuera de contexto. Ampliar la ventana no es una opción en 8 GB de VRAM. Esto refuerza el argumento: sin acceso estructurado a los datos, un 7B local no solo puede equivocarse al leer, sino que con frecuencia ni siquiera *ve* la cifra correcta.

En el otro extremo, la estabilidad del BPA diluido en el baseline *structured* (80%) es instructiva: cuando una magnitud tiene una presentación fuertemente estandarizada (última línea del estado, formato `$X.XX`, etiqueta "*Diluted*"), el modelo la identifica de forma fiable con independencia de cuántos ejercicios aparezcan. La fiabilidad del LLM en extracción numérica no es uniforme, sino una función de la regularidad de la presentación; XBRL elimina esa dependencia.

B. Generalización del principio híbrido

Aunque LUCA se evalúa sobre informes 10-K, el principio que lo vertebra no es específico de las finanzas: en cualquier dominio donde coexistan datos estructurados fiables (una base de datos, un formato etiquetado, una API canónica) y texto no estructurado que requiera interpretación, conviene resolver lo estructurado con código determinista y reservar el modelo de lenguaje para lo que solo el lenguaje puede capturar. La aportación metodológica del trabajo no es un *prompt* ni un modelo concretos, sino la disciplina de trazar y evaluar esa frontera. El hecho de que la misma arquitectura multiagente provenga de un sistema de revisión sistemática en otro dominio refuerza esta lectura: lo que generaliza es la separación de responsabilidades, por encima de los detalles de implementación.

C. Implicaciones prácticas

Para un equipo que quiera desplegar análisis financiero asistido por IA sin enviar datos a terceros ni asumir coste por consulta, los resultados tienen una lectura directa. Primero, las cifras de un informe deben extraerse del dato estructurado (XBRL) siempre que exista, no pedírselas al modelo: el ahorro en errores es de decenas de puntos porcentuales y, además, gratuito y determinista. Segundo, un modelo de 7B local es suficiente para la capa cualitativa si se le entregan fragmentos acotados y se acepta una calidad de prosa moderada; no hace falta un modelo de frontera para producir un borrador útil que un analista revise. Tercero, la trazabilidad debe construirse en el sistema, no en el modelo: las citas literales, los identificadores deterministas y los artefactos intermedios auditables son los que permiten confiar en la salida y revisarla. Estas tres decisiones, más que cualquier ajuste de *prompt*, son las que determinan si el sistema es fiable.

D. Techo de calidad del modelo de 7B

En la capa cualitativa, el mismo modelo de 7B produce un memo legible en español con cifras exactas (deterministas) y un análisis de riesgos fundamentado en lo extraído. Su calidad de prosa es limitada y se reporta como una limitación honesta, no se sustituye por un modelo mayor o externo: la restricción de hardware de consumo es parte de la tesis del trabajo.

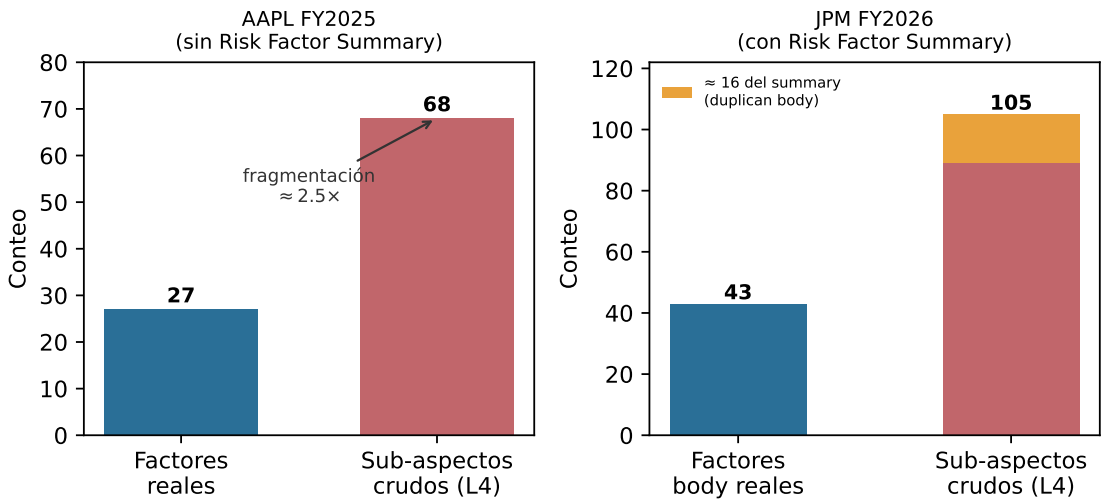


Fig. 4. La validación manual de la extracción de riesgos (L4) frente a los informes muestra que el conteo crudo sobre-estima los factores de riesgo reales, mediante dos mecanismos distintos según la estructura del documento.

E. La sobre-extracción de riesgos no es uniforme

La validación manual de la salida de L4 contra los informes originales revela que el conteo crudo de riesgos sobre-estima el número de factores reales, y que lo hace por dos mecanismos distintos según la estructura del documento (Fig. 4).

En el 10-K de Apple (FY2025), que *no* incluye un *Risk Factor Summary*, el inflado es *pura fragmentación del cuerpo*: los 27 factores de riesgo reales (los 27 encabezados en negrita; las cinco *categorías* quedan aisladas y no generan riesgos) se descomponen en 68 sub-aspectos extraídos (≈2.5×). El extractor produjo al menos un riesgo para 26 de los 27 factores; el factor de procedimientos legales quedó sin riesgos, lo que es una limitación del extractor, no una carencia del documento. Por tanto, "26" es la *cobertura* del extractor, no un conteo de factores.

En el 10-K de JPMorgan (FY2026), que *sí* publica un *Risk Factor Summary*, aparece un segundo mecanismo, la *contaminación summary↔body*: de los bloques estructurales, 13 pertenecen al resumen y un conteo ingenuo los trataría como factores, y el propio resumen está además fragmentado (su único *bullet* "Operational" generó seis sub-riesgos). Al excluir los bloques del resumen y un bloque huérfano previo, quedan 43 factores reales de cuerpo. Alrededor de 16 riesgos derivados del resumen duplican factores del cuerpo. La Tabla IV resume ambos casos.

El valor "26" de AAPL es la cobertura del extractor (cuántos de los 27 factores recibieron al menos un riesgo), no un conteo de factores; lo mantenemos separado de forma deliberada para no confundir una limitación del extractor con la estructura del documento.

TABLE IV
SOBRE-EXTRACCIÓN DE RIESGOS VALIDADA MANUALMENTE. EN AAPL, 27 FACTORES REALES FRENTE A 68 SUB-ASPECTOS CRUDOS (≈2.5×); "26/27" ES LA COBERTURA DEL EXTRACTOR. EN JPM, 43 FACTORES DE CUERPO FRENTE A 105 CRUDOS, CON ≈16 RIESGOS DEL *summary* QUE DUPLICAN EL CUERPO.

Emisor	Factores	Cobertura	Modo de inflado
AAPL	27 (de 68)	26/27	fragmentación
JPM	43 (de 105)	—	fragm. + contam. *summary*

F. Limitaciones

La Tabla V resume las limitaciones del estado actual y su implicación. Más allá de ellas, conviene subrayar que la evaluación cuantitativa cubre la capa numérica (L3) y no todavía la calidad de la capa cualitativa, que se ha validado de forma manual y se documenta como pendiente de evaluación sistemática.

G. Amenazas a la validez

El *gold standard* cubre diez emisores estadounidenses de gran capitalización; los resultados podrían no generalizar a empresas pequeñas, a sectores con taxonomías XBRL atípicas o a jurisdicciones distintas. La precisión de L3 depende además de la completitud y corrección del XBRL que el emisor deposita en EDGAR; un *filing* con etiquetado deficiente degradaría la extracción sin que el sistema lo advierta. La evaluación cuantitativa se limita a seis métricas *core*; `cash` y `long_term_debt`, ya extraídas por el código, no se han anotado y quedan fuera del $N = 60$. Finalmente, la comparación de baselines usa un único modelo (Qwen 2.5 7B) y una única GPU; no exploramos otros modelos de

TABLE V
LIMITACIONES DEL ESTADO ACTUAL E IMPLICACIÓN.

Limitación	Implicación
Sobre-extracción de riesgos	El conteo crudo de L4 infla los factores reales (≈2.5× en AAPL); requiere una capa de deduplicación.
Contaminación de *summary*	En emisores con *Risk Factor Summary* hay duplicación *summary*↔*body*.
Calidad de prosa del 7B	Limitada; reportada como restricción de hardware, no corregida con un modelo mayor.
No determinismo del LLM	Los baselines y la capa cualitativa varían entre ejecuciones; L3 es determinista.
Cobertura de categorías	Reputación y conducta no están entre las seis categorías del config.
Solo HTML de EDGAR	No se cubren los PDF no estructurados (p. ej. CNMV).

tamaño equivalente, por coherencia con la tesis de hardware de consumo.

H. Reproducibilidad

L3 es totalmente determinista (XBRL, sin LLM): su 100% no tiene varianza. Los baselines LLM y la capa cualitativa no son deterministas por *seed*, porque el cliente de Ollama no propaga la semilla; cabe esperar una variación de $\pm$1–2 filas entre ejecuciones en los baselines. Por ello reportamos la brecha como un rango (≈48–50 pp) y no como un valor exacto. Las cifras de las tablas y figuras se regeneran desde los CSV de evaluación mediante un único script, lo que garantiza que el texto y los gráficos no diverjan.

VIII. TRABAJO FUTURO

El análisis de sobre-extracción motiva una **capa de deduplicación** entre L4 y L5 con dos responsabilidades, para las cuales la salida actual ya aporta las señales necesarias: (i) *mapear los sub-aspectos extraídos a los encabezados en negrita* (los anclajes del *chunker*), de modo que la fragmentación del cuerpo colapse a una entrada por factor real; y (ii) *detectar y descartar el bloque Risk Factor Summary* cuando exista, usando la marca `in_summary` ya disponible, para que los *bullets* del resumen no se cuenten como factores ni dupliquen el cuerpo. La fragmentación ocurre en todo emisor, mientras que la contaminación *summary*↔*body* solo aparece en quienes publican un resumen.

Más allá de la deduplicación, la calidad de la capa cualitativa requiere una **evaluación sistemática** que en este trabajo solo se ha abordado de forma manual. Planteamos como línea futura una rúbrica de evaluación del memo (L7) sobre tres ejes: completitud (cobertura de las secciones esperadas), coherencia interna y fidelidad al documento fuente, esta última apoyada en las citas literales que L4 ya conserva. Para la extracción de riesgos (L4) y su clasificación (L5), proponemos medir precisión y exhaustividad contra un *gold standard* cualitativo anotado por un humano, análogo al numérico, una vez que la capa de deduplicación estabilice el conteo de factores. El diagnóstico de los casos sin clasificar es además accionable: parte de ellos refleja un *gap* de cobertura del vocabulario (reputación y conducta no están entre las seis categorías), que se corrige ampliando el conjunto, y parte es inestabilidad de la salida en lote, que se corrige reduciendo el tamaño de lote.

Quedan también como líneas futuras: la extracción de *forward-looking statements* y el análisis de tono directivo (fuera del alcance de L4 en esta iteración); los agentes L6 (comparables) y L8 (*explainability* en Excel); la anotación y evaluación de las métricas `cash` y `long_term_debt` (ya extraídas por L3 a nivel de código, pero no anotadas en el *gold standard* y, por tanto, fuera del $N = 60$); la ampliación del vocabulario de categorías de riesgo con *reputation* y *conduct*; y el soporte de PDF no estructurados (p. ej. CNMV), que permitiría además estudiar cómo varía la calidad de extracción entre HTML estructurado y PDF.

IX. CONCLUSIÓN

LUCA muestra que una arquitectura híbrida, en la que las cifras provienen de XBRL y un modelo de 7B local se reserva para lo cualitativo, permite alcanzar una precisión numérica del 100% determinista sobre un *gold standard* de 60 puntos de dato, frente al ≈50% del mejor baseline LLM-only y al 3.3% de un baseline ingenuo, una brecha de ≈48–50 pp. El sistema completo se ejecuta en una GPU de consumo de 8 GB sin recurrir a modelos externos ni APIs de pago, lo que respalda la viabilidad de la tesis de hardware de consumo. En la capa cualitativa, el modelo de 7B produce memos utilizables pero con una calidad limitada y un patrón de sobre-extracción de riesgos que caracterizamos en dos mecanismos distintos; lo reportamos como límite honesto y como motivación directa del trabajo futuro, sin sobre-atribuir capacidades al sistema.

La lectura más amplia del trabajo es que, en dominios documentales con datos estructurados disponibles, la pregunta relevante no es "¿qué modelo de lenguaje usar?" sino "¿qué parte del problema no debería resolver el modelo de lenguaje?". Responderla con una frontera explícita y medible entre lo determinista y lo generativo es lo que permite que un modelo de 7B en una GPU de consumo entregue resultados de grado experto en la parte numérica, al tiempo que se reconocen con honestidad los límites de su parte cualitativa. Esa combinación, precisión verificable donde el dato lo permite y transparencia sobre las limitaciones donde no, es un camino practicable para desplegar análisis financiero asistido por IA sin depender de modelos cerrados de gran escala.

REFERENCIAS

[1] Z. Ji, N. Lee, R. Frieske, T. Yu, D. Su, Y. Xu, E. Ishii, Y. J. Bang, A. Madotto, and P. Fung, "Survey of hallucination in natural language generation," *ACM Computing Surveys*, vol. 55, no. 12, 2023.

[2] Z. Chen, W. Chen, C. Smiley, S. Shah, I. Borova, D. Langdon, R. Moussa, M. Beane, T.-H. Huang, B. Routledge, and W. Y. Wang, "FinQA: A dataset of numerical reasoning over financial data," in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2021.

[3] F. Zhu, W. Lei, Y. Huang, C. Wang, S. Zhang, J. Lv, F. Feng, and T.-S. Chua, "TAT-QA: A question answering benchmark on a hybrid of tabular and textual content in finance," in *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2021.

[4] S. Wu, O. Irsoy, S. Lu, V. Dabravolski, M. Dredze, S. Gehrmann, P. Kambadur, D. Rosenberg, and G. Mann, "BloombergGPT: A large language model for finance," *arXiv preprint arXiv:2303.17564*, 2023.

[5] D. Araci, "FinBERT: Financial sentiment analysis with pre-trained language models," *arXiv preprint arXiv:1908.10063*, 2019.
[6] J. Wei, X. Wang, D. Schuurmans, M. Bosma, B. Ichter, F. Xia, E. Chi, Q. Le, and D. Zhou, "Chain-of-thought prompting elicits reasoning in large language models," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
[7] S. Yao, J. Zhao, D. Yu, N. Du, I. Shafran, K. Narasimhan, and Y. Cao, "ReAct: Synergizing reasoning and acting in language models," in *International Conference on Learning Representations (ICLR)*, 2023.
[8] Q. Wu, G. Bansal, J. Zhang, Y. Wu, B. Li, E. Zhu, L. Jiang, X. Zhang, S. Zhang, J. Liu, A. Awadallah, R. W. White, D. Burger, and C. Wang, "AutoGen: Enabling next-gen LLM applications via multi-agent conversation," *arXiv preprint arXiv:2308.08155*, 2023.
[9] H. Touvron, T. Lavril, G. Izacard *et al.*, "LLaMA: Open and efficient foundation language models," *arXiv preprint arXiv:2302.13971*, 2023.
[10] Qwen, A. Yang *et al.*, "Qwen2.5 technical report," *arXiv preprint arXiv:2412.15115*, 2024.